

# Análise de Mídias Sociais e Mineração de Texto

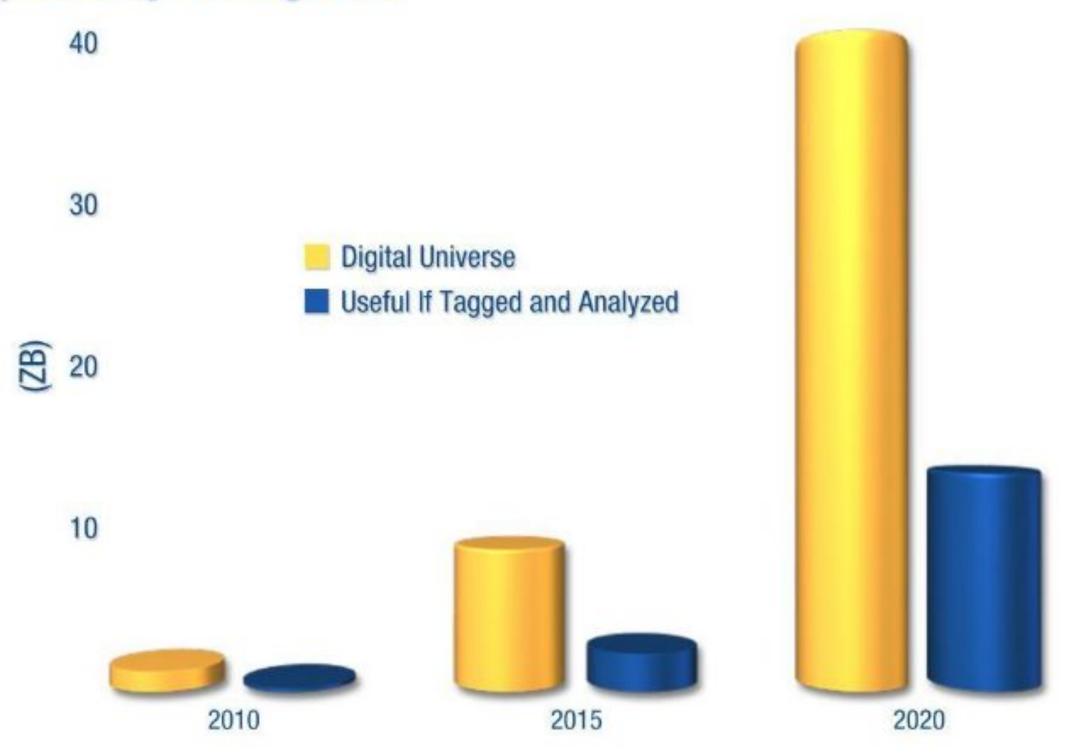
Mineração de Texto

Laura de Oliveira F. Moraes

# Por que?



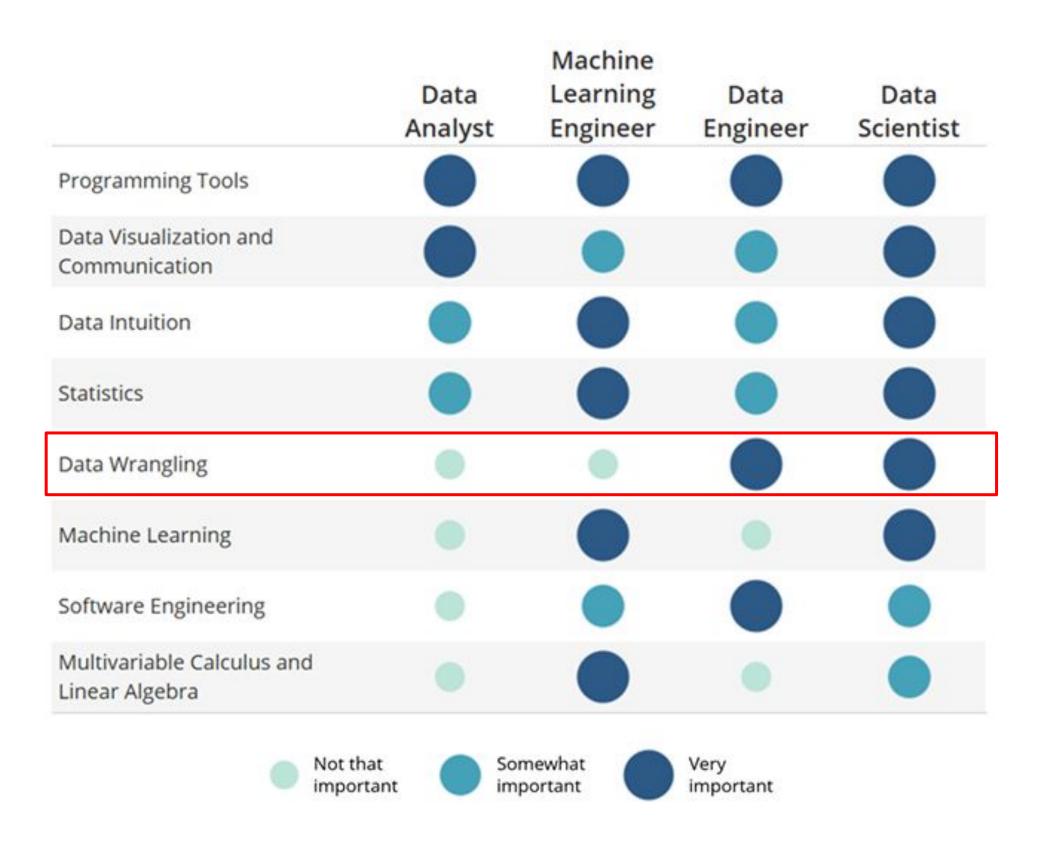
# Opportunity for Big Data



Source: IDC's Digital Universe Study, sponsored by EMC, December 2012

## Por que?





# Processamento de Linguagem Natural



NLP são **métodos** para computadores **analisarem, entenderem e obterem significados** para a linguagem humana de uma **maneira inteligente** e útil

# Processamento de Linguagem Natural



NLP são **métodos** para computadores **analisarem, entenderem e obterem significados** para a linguagem humana de uma **maneira inteligente** e útil

Compreensão da Linguagem

Representar a linguagem

Analisar diferentes aspectos da linguagem

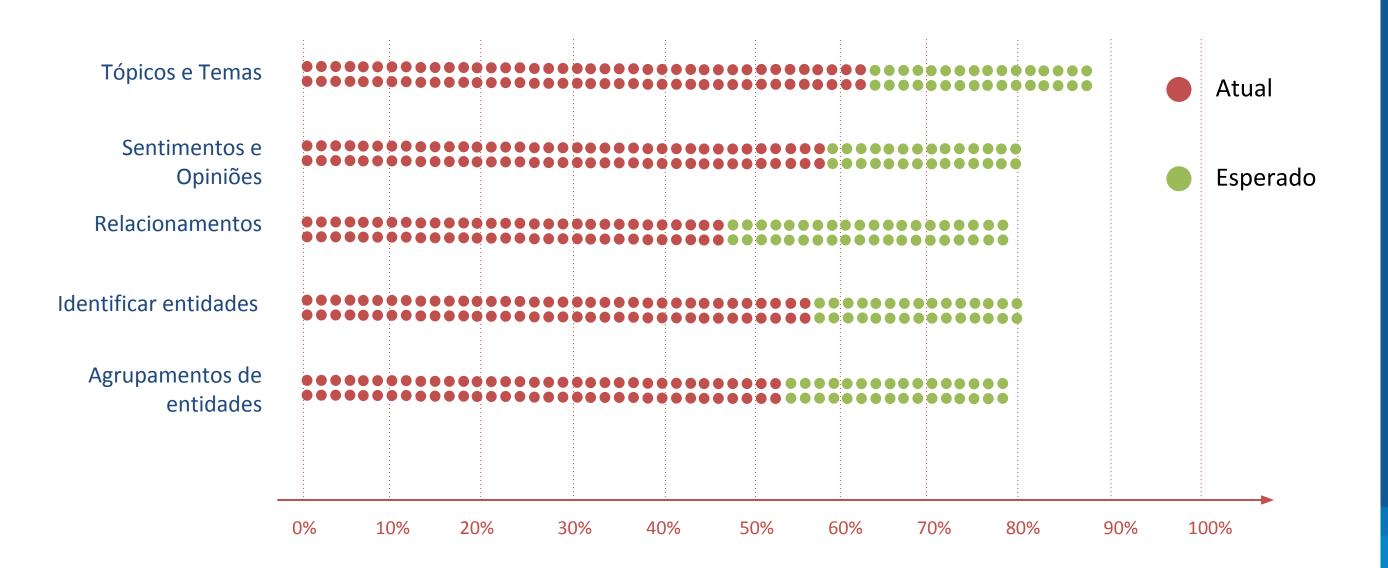
Geração da Linguagem

**Produzir** conteúdo significativo

Entre outras aplicações: Bots



# Sobre análises de conteúdo textual, o que você necessita, ou espera ter como necessidade?



Fonte: http://altaplana.com/TA2014

#### Casos



#### Painel Vila Olímpica





# Telefonica 2000 Total Febrero Marzo Abril Oficial

Mayo

#### Prefeitura Vila Olímpica





# **Common NLP Tasks**



Easy



Medium



Hard

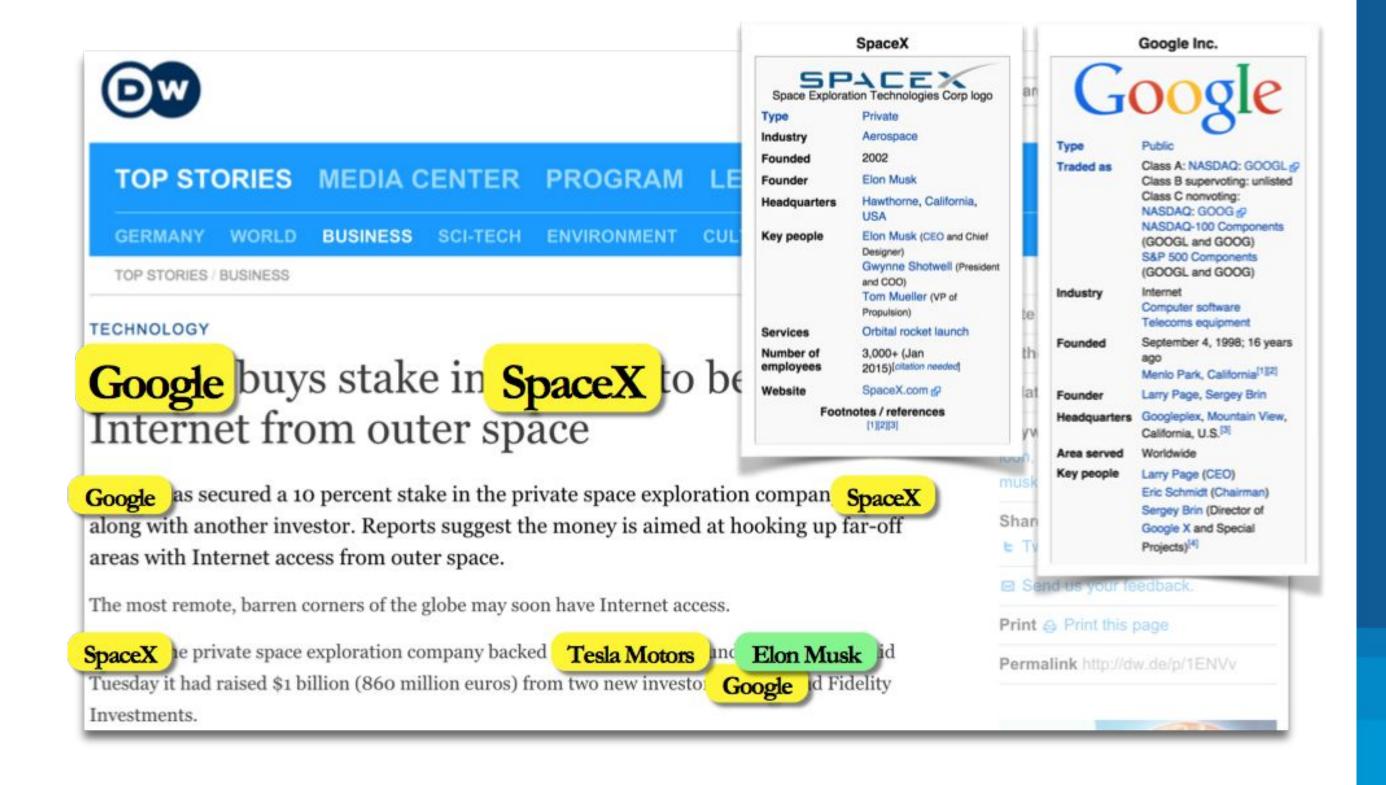
- Chunking
- Part-of-Speech Tagging
- Named Entity Recognition
- Spam Detection
- Thesaurus

- Syntactic Parsing
- Word Sense Disambiguation
- Sentiment Analysis
- Topic Modeling
- Information Retrieval

- Machine Translation
- Text Generation
- Automatic Summarization
- Question Answering
- Conversational Interfaces



# Dados não-estruturados, enriquecidos



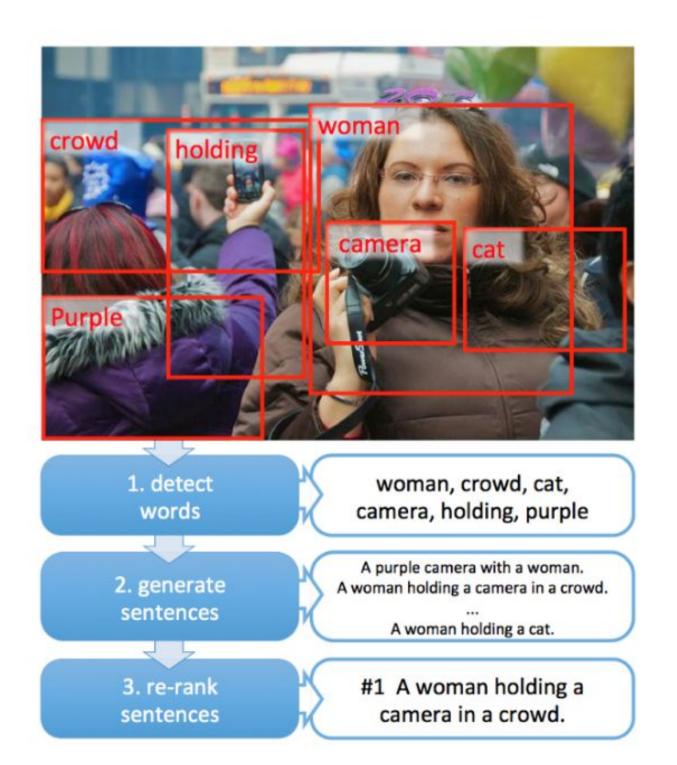
# Interdisciplinaridade: Fala-para-Texto





# Interdisciplinaridade: Legenda para Imagens TFGV







## Por que NLP é difícil?



- Ambiguidade
- Linguagem não-formal: gírias, neologismos
- Ironia
- Idiomas complexos:
  - Alemão: Donaudampfschiffahrtsgesellschaftskapitän (5 palavras)
  - Chinês: 50.000 caracteres diferentes (2-3 mil em um jornal)
  - Japonês: 3 sistemas de escrita
  - Etc



# Write Traditional "If-Then-Else" Rules?

#### **BIG NOPE!**

Leads to very large and complex codebases.

Still struggles to capture trivial cases (for a human).



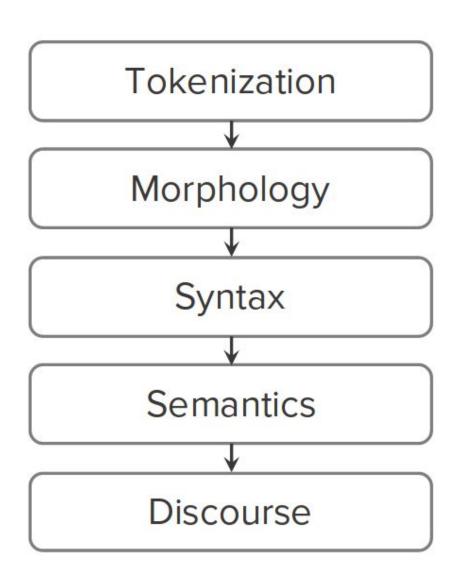
# Better Approach: Machine Learning

- A computer program is said to learn from experience E
  - with respect to some class of tasks T and performance measure P,
  - if its performance at tasks in T, as measured by P,
  - improves with experience E.

Tom M. Mitchell

### **NLP Pipeline**





Break text into sentences and words, lemmatize

Part of speech (POS) tagging, stemming, NER

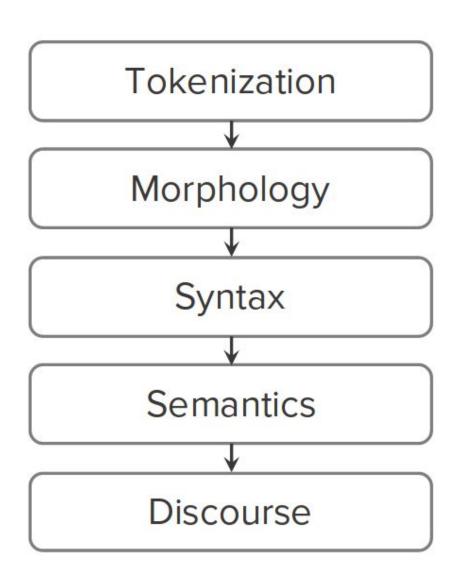
Constituency/dependency parsing

Coreference resolution, wordsense disambiguation

Task-dependent (sentiment, ...)

### **NLP Pipeline**





Break text into sentences and words, lemmatize

Part of speech (POS) tagging, stemming, NER

Constituency/dependency parsing

Coreference resolution, wordsense disambiguation

Task-dependent (sentiment, ...)

#### Interessado?



- https://github.com/laugustyniak/awesome-sentiment-analysis
- https://github.com/Kyubyong/nlp\_tasks